

3. Matriz de Costos y Optimización de Modelos

Tarea / Componente	Modelo / Servicio Seleccionado	Justificación Técnica	Costo Estimado / Token
Procesamiento de Tickets e Inferencia RAG	Cohere Command R (Cohere Chat Model)	Excelente rendimiento para tareas estructuradas (JSON), RAG y bajo consumo de tokens sin sacrificar precisión narrativa.	~\$0.0005 / 1k input tokens ~\$0.0015 / 1k output tokens
Parsing y Formateo Estricto	Structured Output Parser (n8n native)	Garantiza la integridad de los campos JSON sin requerir llamadas adicionales a la API, optimizando costos.	\$0.00 (Integ. Nativa)
Orquestación y Lógica	n8n Cloud (Pro / Self-Hosted)	Permite manejar suspensiones de estado (HITL Form) y rutas condicionales con baja latencia.	Según ejecuciones (~\$50/mes)
Base de Conocimiento y Registros	Notion API	Funciona como memoria del sistema sin costo por API call en workspaces estándar.	Incluido